

IoT Ağ Trafiğinde Saldırı Tipi Sınıflandırması

Büyük Veri Projesi Raporu

Veri Seti Edge-IIoTset Cyber Security Dataset
Teknolojiler Kafka, Spark, Delta Lake, MLflow, Streamlit
Tarih Mayıs 2025

İçindekiler

1	Giriş	2
2	Veri Seti	2
3	Sistem Mimarisi	2
4	Veri Pipeline'ı	3
4.1	Kafka Producer	3
4.2	Medallion Architecture (Delta Lake)	3
5	Feature Engineering	3
6	Makine Öğrenmesi Modelleri	3
6.1	Ortak Pipeline	3
6.2	Eğitilen Modeller	4
6.3	Değerlendirme Metrikleri	4
7	MLflow Deney Takibi	4
8	Streamlit Dashboard	4
9	Sonuç	4
	Kaynakça	5

1 Giriş

Bu proje, **Edge-IIoTset** veri setini kullanarak IoT ağ trafiği üzerinde çok sınıflı (multi-class) saldırı tipi sınıflandırması yapan uçtan uca bir büyük veri pipeline'ı sunar. Kafka ile gerçek zamanlı akış, Spark ile dağıtık işleme, Delta Lake ile katmanlı depolama, 5 ML modeli, MLflow ile deney takibi ve Streamlit dashboard bileşenleri Docker Compose ile orkestre edilir.

Amaç: Gelen her ağ paketinin saldırı türünü (Normal, DDoS, Port Scanning, MITM, Ransomware vb.) yüksek doğrulukla sınıflandırmak.

2 Veri Seti

Kaynak	Kaggle (Mohamed Amine Ferrag)
Dosya	ML-EdgeIIoT-dataset.csv (~82 MB)
Kolon	63 (TCP, UDP, HTTP, DNS, MQTT, Modbus vb.)
Sınıf	14+ saldırı tipi + Normal
Hedef	Attack_type

Her satır bir ağ paketini temsil eder. Paket yalnızca bir protokol kullandığından, diğer protokol kolonları doğa olarak 0'dır (eksik değer değil, aktivite yok).

3 Sistem Mimarisi

Tüm bileşenler `docker compose up -d` ile ayağa kalkar.

Bileşen	Teknoloji	Port
Mesaj Kuyruğu	Kafka 3.4 + Zookeeper	9092
Dağıtık İşleme	Apache Spark 3.4.2	8080
Depolama	Delta Lake 2.4.0	—
ML Takip	MLflow	5000
Dashboard	Streamlit	8501
Notebook	JupyterLab	8888

Spark cluster: 1 master + 1 worker (2 GB RAM, 2 core).

4 Veri Pipeline'ı

4.1 Kafka Producer

CSV kayıtlarını JSON'a çevirip `iot-network-traffic` topic'ine (3 partition) gönderir. Her mesaja `timestamp`, `flow_id`, IP adresleri eklenir.

4.2 Medallion Architecture (Delta Lake)

1. **Bronze:** Ham JSON'u değiştirmeden Delta'ya yazar (yıl/ay/gün partition).
2. **Silver:** JSON parse, kolon rename, 8 gereksiz kolon drop, inf temizleme, eksik değer doldurma, tip cast, duplikat kaldırma.
3. **Gold:** Silver + 5 yeni feature $\Rightarrow$ ML-ready tablo.

Her katman 30s micro-batch ile Structured Streaming olarak çalışır.

5 Feature Engineering

Silver verisine eklenen 5 özellik:

#	Feature	Formül	Hedef Saldırı
1	<code>traffic_asymmetry_ratio</code>	$\frac{\text{tcp_ack}}{\text{tcp_seq}+1}$	DDoS Flood
2	<code>pkt_size_cv</code>	$\frac{\text{tcp_len}}{ \text{seq}-\text{ack} +1}$	Port Scan
3	<code>flow_intensity</code>	$\text{tcp_len} \times \text{tcp_flags}$	DDoS UDP
4	<code>iat_regularity</code>	$\frac{\text{tcp_checksum}}{\text{tcp_len}+1}$	Brute Force
5	<code>conn_efficiency</code>	$\frac{\text{syn}}{\text{fin}+\text{rst}+1}$	SYN Flood

6 Makine Öğrenmesi Modelleri

6.1 Ortak Pipeline

1. Gold Delta'dan batch okuma
2. `StringIndexer` ile `Attack_type` $\rightarrow$ sayısal label
3. `VectorAssembler` ile feature vektörü
4. Balanced class weight: $w_c = \frac{N}{K \cdot N_c}$
5. Stratified train/test split (%80/%20, seed=42)

6.2 Eğitilen Modeller

#	Model	Özellik
1	Logistic Regression	Multinomial, StandardScaler, elasticNet CV
2	Decision Tree	maxDepth/minInstances CV, Gini impurity
3	Random Forest	50–200 ağaç, bagging ensemble
4	GBT (OneVsRest)	N binary GBT, boosting ensemble
5	Naive Bayes	MinMaxScaler, multinomial/complement

Tüm modeller `CrossValidator` ile F1-Score optimizasyonu yapar.

6.3 Değerlendirme Metrikleri

Accuracy, Weighted F1, Precision, Recall, Log Loss ve $N \times N$ Confusion Matrix.

7 MLflow Deney Takibi

Her eğitim sonrası MLflow'a loglanan bilgiler:

- **Metrikler:** accuracy, f1, precision, recall, per-class P/R/F1
- **Parametreler:** tüm hiperparametreler, CV config
- **Artifact'lar:** confusion_matrix.csv, feature importance (PNG+CSV), Spark model
- **Tag'ler:** classification_type, num_classes, model tipi

Backend: SQLite + artifact store. UI: <http://localhost:5000>.

8 Streamlit Dashboard

6 sayfalık interaktif web arayüzü:

#	Sayfa
1	Genel Bakış (sistem durumu)
2	Veri Akışı (Kafka → Delta izleme)
3	EDA (dağılım, korelasyon)
4	Feature Engineering (5 feature detayı)
5	Model Karşılaştırma (F1 sıralı)
6	En İyi Model (production tavsiyesi)

9 Sonuç

Proje, IoT ağ güvenliği için gerçek zamanlı veri toplama, temizleme, feature üretimi ve çok sınıflı sınıflandırmayı tek bir platform altında birleştirmiştir. 5 farklı model eğitilmiş,

MLflow ile karşılaştırılmış ve Streamlit üzerinden görselleştirilmiştir. Gelecek adımlar: deep learning modelleri, real-time inference, otomatik alert sistemi.

Kaynakça

1. Ferrag, M.A. et al. “Edge-IIoTset: A New Comprehensive Realistic Cyber Security Dataset.” *IEEE Access*, 2022.
2. Zaharia, M. et al. “Apache Spark: A Unified Engine for Big Data Processing.” *CACM*, 2016.
3. Armbrust, M. et al. “Delta Lake: High-Performance ACID Table Storage.” *VLDB*, 2020.
4. Apache Kafka Documentation. <https://kafka.apache.org/documentation/>
5. MLflow Documentation. <https://mlflow.org/docs/latest/index.html>